IPASI

PÓS-GRADUAÇÃO EM
INTELIGÊNCIA ARTIFICIAL APLICADA À INOVAÇÃO

Programação em Python para Tratamento de Dados

PROFESSOR
Dr. Ademir Batista

PLANO DE AULA

Programação em Python para Tratamento de Dados

A base de qualquer projeto de Inteligência Artificial

Ferramentas: Pandas e VS Code

python™ + pandas

Motor de Processamento

A combinação da simplicidade do Python com a robustez do Pandas.

Ambiente de Desenvolvimento

Uma IDE moderna que integra extensões, terminal e controle de versão.

O Fluxo de Tratamento

1

Diagnóstico

Identificar valores nulos e tipos de dados incorretos.

`.info()` `.isnull()`

2

Limpeza

Remover duplicatas e tratar anomalias nos registros.

Eliminação de ruídos

3

Transformação

Preenchimento valores ausentes e casting e feature engineering.

Padronização final

Desafio Prático

titanic_raw.csv

```
df_titanic[['PassengerId', 'Survived', 'Name', 'Sex', 'Age',
'Cabin']].head(5)
```

Id	Surv	Pclass	Name	Sex	Age	Cabin
1	0	3	Braund, Mr. Owen ...	male	22	NaN
2	1	1	Cumings, Mrs. Jo ...	female	38	C85
3	1	3	Heikkinen, Miss ...	female	26	NaN
4	1	1	Futrelle, Mrs. J ...	female	35	C123
5	0	3	Allen, Mr. Willi ...	male	35	NaN

891 linhas x 12 colunas

Acesse o Dataset Titanic

Utilize o arquivo disponível no GitHub do DataScienceDojo (link no QR Code).

Aplique o Tratamento

Identifique os nulos (`isnull()`) em 'Age' e 'Cabin' e decida a estratégia (remoção ou imputação).

Análise

Verifique se é possível gerar outras features a partir das atuais.

Dataset Completo

Escaneie para baixar
Fonte: UCI / Kaggle

Obrigado!

Dúvidas e discussões são bem-vindas.

Dr. Ademir Batista

EMAIL
ademir.bsn@gmail.com

MATERIAL DA AULA
github.com/ademirNeto/aula_ipasi